AVANCE 2026

Crimen y Rendimiento Escolar en Santiago

Construcción del pipeline de datos · Validación del índice de criminalidad · Sanity check

3,678,197
denuncias policiales

32,519
registros SIMCE

8
scripts · Pipeline v3

2013–2019
período analizado

Región Metropolitana de Santiago | 35 comunas con cobertura policial | 1,417 establecimientos

Realizado por Camila Vera Villa | marzo 2026

Temas a revisar

01 Contexto y fuentes de datos

02 Arquitectura del pipeline — 8 scripts

03 Índice de criminalidad: ranking, score y fórmula

04 Data prep: establecimientos y SIMCE

05 Cruce espacial: geocódigos, buffers y cobertura

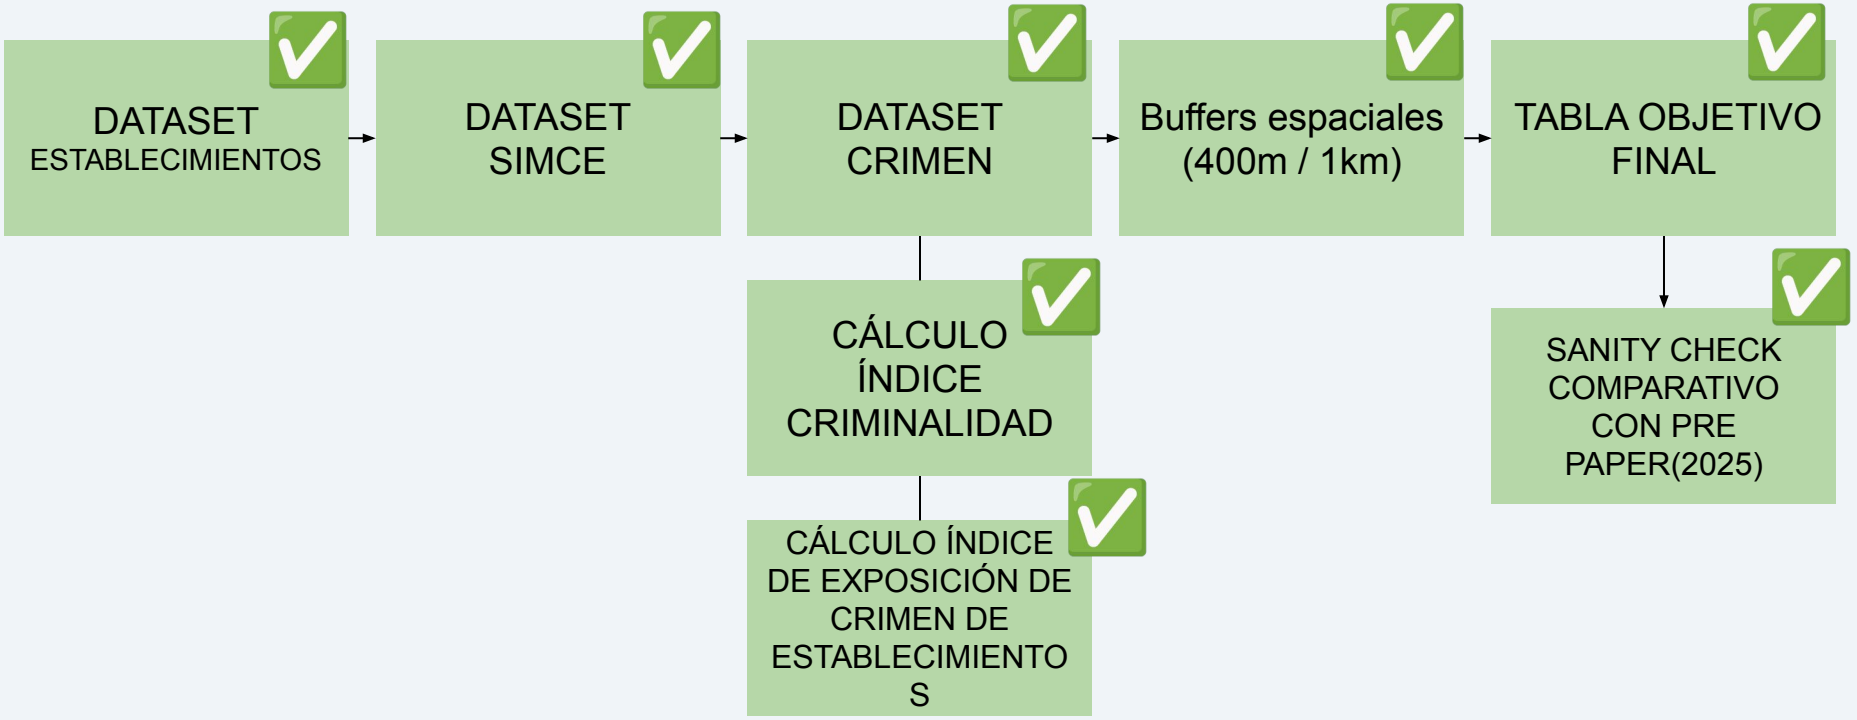
06 Tabla final y especificación econométrica

07 Resultados y sanity check vs. paper

08 Links útiles

Contexto

CREACIÓN PIPELINE COMPLETO



01

Contexto y Fuentes de Datos

¿Qué construimos y con qué datos?

¿Qué construimos?

Pipeline reproducible

8 scripts modulares en Python que van desde los datos crudos hasta los modelos de regresión como sanity check. Cada script puede correrse de forma independiente.

Índice de criminalidad

Ranking manual de 98 tipos de delito en 8 niveles de severidad. Dos versiones del índice: Global (v2) y Cluster (v3), análogos al pre paper de referencia (2025).

Cruce espacial

Buffer espacio-temporal: 6 ventanas (7–365 días) × 2 radios (400m, 1km) × 24 combos año-grado SIMCE = 595,152 observaciones de exposición al crimen.

Replicación como sanity check

El Script 08 replica la especificación del paper (OLS con HC3) y compara resultados. Diferencias en N explicadas y documentadas.

Fuentes de datos

01 Registros Policiales (CEAD / Carabineros)

- 3,678,197 denuncias
- mayo 2013 – sep. 2022
- 35 comunas RM

Archivo base de dropbox: *resumen_fecha_zona.csv* →*listado_delitos.csv* (cambié el nombre)

02 SIMCE (Agencia de Calidad)

- 32,519 registros RBD×año×grado
- 2013–2019 · 5 grados
- Lenguaje + Matemáticas

Archivo base de dropbox: limpié el archivo *simce_completo_5.dta*

03 Directorio MINEDUC (Establecimientos)

- 4,133 RBDs con coordenada
- 2013–2019 (7 versiones)
- Coordenada madre calculada

Archivos base de https://datosabiertos.mineduc.cl/

04 Shapefile INE (Manzanas censales RM)

- 46,002 sub-manzanas
- → 1,655 manzanas (11 dígitos GEOCODE)
- CRS: EPSG:4674 → UTM 19S

Archivo base de cartografía del INE, Censo 2017. https://www.ine.gob.cl/herramientas/portal-de-mapas/geodatos-abiertos

Dataset de Crimen — características principales

98
tipos de delito distintos

35
comunas con cobertura

1,655
manzanas censales con crimen

9.4 años
período cubierto (2013–2022)

Estructura del dato crudo (listado_delitos.csv)

Campo	Contenido	Ejemplo
fecha	Fecha del delito	2015-10-09
GEOCODIGO	Código de manzana censal (11 dígitos)	13101001001
delito	Tipo de delito (98 categorías)	Robo con violencia o intimidación
frecuencia	Número de denuncias ese día en esa manzana	3

02

Arquitectura del Pipeline

8 scripts modulares en Python

Flujo del Pipeline — 8 scripts secuenciales

01
Severity Lookup
Ranking 98 delitos

02
Validate Lookup
Recomputa scores

03
Crime Index
Por geocódigo × día

04
Schools Prep
Coordenada madre

05
SIMCE Prep
Fechas + controles

06
Spatial Buffers
400m / 1km · 6 ventanas

07
Final Table
Une educación + crimen

08
Regression
OLS con HC3 · 45 modelos

OUTPUT FINAL: `data/processed/tabla_final_escuelas_crimen.parquet` + `data/resultados/regression_*.csv`

Diseño modular

project_paths.py centraliza todas las rutas. Si se modifica la estructura de carpetas, basta con editar ese único archivo. Cada script puede correrse de forma aislada si sus inputs ya existen, no es necesario re-ejecutar el pipeline desde cero.

Tabla Resumen de scripts (Python)

Script	Archivo	Función principal	Input principal	Output principal
01	create_crime_severity_lookup	Ranking manual 98 delitos → score_gravedad	listado_delitos.csv	crime_severity_lookup.csv
02	validate_and_score_lookup	Recomputa scores sin tocar datos crudos	crime_severity_lookup.csv	crime_severity_lookup.csv (actualizado)
03	create_crime_index_by_geocode	Agrega crimen por geocódigo × día → índice	listado_delitos.csv + lookup	crime_index_geocode_daily.csv
04	dataprep_schools	Limpia establecimientos, calcula coord. madre	Dir. MINEDUC 2013–2019	school_locations_RM.parquet
05	dataprep_education	SIMCE listo para análisis: normalizaz. Stata	simce_completo_5.dta + Script 04	data_education_2013_2019_RM.parquet
06	spatial_buffers	Exposición al crimen por escuela (buffer IDW)	Scripts 03+04+05 + shapefile INE	crime_exposure_400m/1km.parquet
07	final_table	Une educación + crimen + flags geográficos	Scripts 05+06	tabla_final_escuelas_crimen.parquet
08	regression_analysis	OLS con HC3 · 45 modelos · 2 índices	Script 07	regression_global/cluster_index.csv

03

Índice de Criminalidad

Scripts 01–03 · Ranking · Score · Fórmula del índice

Scripts 01–02 · Ranking de severidad — 98 tipos de delito

Estructura del lookup (crime_severity_lookup.csv)

Columna	Descripción
delito	Nombre exacto del tipo de delito (98 únicos)
rank_gravedad	Ranking manual: 1=más grave (Homicidio) … 98=menos grave
score_gravedad	Score normalizado [0,1] — calculado automáticamente
nivel_gravedad	Nivel 1–8 según categoría de severidad
grupo_gravedad	Nombre del grupo (ej: 'violencia_letal_extrema')
comentario	Campo libre para anotaciones (no entra en cómputos)

Editable por diseño

El ranking vive en el código fuente del Script 01. Cualquier ajuste de criterio requiere solo editar RANKING_PROPUESTO y re-correr Script 02 sin tocar datos crudos.

Validación automática

- Verifica ranks 1..98 sin saltos
- Todos los delitos del CSV deben tener rank asignado
- Delitos en ranking pero sin dato = advertencia
- El script falla con error descriptivo si hay inconsistencia

Script 01 · Fórmula del Score de Gravedad

$$score_gravedad = (max_rank - rank_gravedad) / (max_rank - 1) = (98 - rank) / 97$$

donde max_rank = 98 (total de tipos de delito en el dataset)

Ejemplos:

Delito	Rank	Score
Homicidio	1	1.000
Secuestro	2	0.990
Robo con violencia	6	0.948
Lesiones leves	31	0.691
Tráfico de droga	47	0.526
Ley de tránsito	80	0.186
Desacato autoridad	98	0.000

Propiedades del score

- Escala [0, 1] — igual al paper original
- Distribución lineal entre extremos
- Homicidio siempre = 1.0
- Mayor rank → menor score
- Calculado automáticamente — no editable directamente
- Puede ajustarse modificando el ranking

Script 01 · 8 Niveles de Gravedad Criminal

Nivel	Nombre	Ranks	Score	Ejemplos de delitos incluidos
1	violencia_letal_extrema	1–5	1.00–0.96	Homicidio, Secuestro, Violación, Trata de personas, Tráfico de armas
2	violencia_grave	6–12	0.95–0.89	Robo con violencia, Lesiones graves, Violencia intrafamiliar (mujer, NNA, AM)
3	armas_y_robos	13–26	0.88–0.75	Porte ilegal de armas, Robo vehículo, Robo en lugar habitado, Robo por sorpresa
4	propiedad_lesiones_sexuales	27–46	0.74–0.54	Hurto, Lesiones leves, Abuso sexual, Delitos informáticos
5	drogas	47–52	0.53–0.48	Tráfico de droga, Microtráfico, Cultivo, Consumo, Porte de droga
6	economicos_institucionales	53–65	0.47–0.34	Falsificación, Cohecho, Daños, Hallazgo de armamento/droga
7	orden_publico_infracciones	66–81	0.33–0.18	Quebrantamiento de sentencia, Ley de tránsito, Ley de alcoholes
8	incivilidades	82–98	0.17–0.00	Ruidos molestos, Ebriedad, Ley de tabaco, Mala conducta menor

Script 03 · Fórmula del Índice de Delictualidad

$$\text{indice_delictualidad} = \Sigma(\text{frecuencia_i} \times \text{score_gravedad_i}) \;/\; \Sigma(\text{frecuencia_i})$$

donde i indexa tipos de delito en un GEOCODIGO y fecha dados · = 0 si no hay delitos

Promedio ponderado

Cada tipo de delito entra en proporción a su frecuencia. Delitos más frecuentes pesan más en el índice.

Rango [0, 1]

0 = no hay crimen ese día en esa manzana. 1 = solo homicidios. Los valores reales tienden a concentrarse en [0.3–0.7].

Temporal y espacial

Se calcula por (GEOCODIGO × fecha). El Script 06 luego agrega esto al nivel (RBD × ventana × radio).

Reproducible

La lógica es igual a la del paper original. El único cambio posible es el ranking, que es editable.

$$\text{indice delictualidad} = \frac{\sum_i (\text{frecuencia}_i \times \text{ranking normalizado}_i)}{\sum_i \text{frecuencia}_i}$$

04

Datasets: Establecimientos y SIMCE

Scripts 04–05 · Coordenada madre · Normalización

Script 04 · Establecimientos — Coordenada madre

El problema

Un mismo RBD puede tener coordenadas distintas según el año del directorio MINEDUC — por errores de captura, redondeo o actualización de registros.

Año	Latitud reportada
2013	-33.4502
2014	-33.4502
2015	-33.4503
2016	-33.4502
2017	-33.4589 ← error
2018	-33.4502
2019	-33.4502

La solución: coordenada madre

Para cada RBD, se calcula la moda de la latitud y longitud redondeadas a 4 decimales. La moda es robusta ante outliers por error de captura.

```
lat_madre = moda( round(lat, 4) )
lon_madre = moda( round(lon, 4) )
```

- 4 decimales ≈ 11 metros de precisión
- Suficiente para buffers de 400m y 1km
- Moda > media: no desplaza coordenada por outlier
- RBDs sin ninguna coordenada válida (109): son jardines JUNJI u otros sin evaluación SIMCE ⟶ excluidos correctamente

Script 05 · SIMCE — Normalización de variables

Problema al hacer el filtrado stata/py

El archivo simce_completo_5.dta usa variables categóricas Stata con esquemas de enteros distintos según el período. pd.read_stata() con convert_categoricals=True (defecto) falla silenciosamente al hacer .copy() sobre subconjuntos. Solución: leer con convert_categoricals=False y mapear enteros directamente.

Variable	Años 2013–2017 (entero Stata)	Años 2018–2019 (entero Stata)	Mapeo aplicado
cod_depe2 (dependencia administrativa)	1=Municipal 2=Part. Subvencionado 3=Part. Pagado	4=Municipal 5=Part. Subvencionado 6=Part. Pagado 7→NaN (residual)	{ 1→1, 2→2, 3→3, 4→1, 5→2, 6→3 }
cod_grupo (grupo socioeconómico)	1=Bajo 2=Medio bajo 3=Medio 4=Medio alto 5=Alto	6=Bajo 7=Medio bajo 8=Medio 9=Medio alto 10=Alto	{ 1→1, 2→2, 3→3, 4→4, 5→5, 6→1, 7→2, 8→3, 9→4, 10→5 }

Validar

¿Es correcto tratar cod_depe2=7 (código residual de 2018–2019) como NaN? Afecta 91 observaciones (~0.3% de la muestra). Podrían ser establecimientos con dependencia híbrida o en transición.

Script 05 · Fechas Exactas de Rendición SIMCE

Confirmado empíricamente: hay exactamente 1 fecha distinta por combinación año-grado sobre 32,519 registros.
Las ventanas temporales del Script 06 se anclan a estas fechas.

Año	2° Básico	4° Básico	6° Básico	8° Básico	2° Medio
2013	29 oct	09 oct	23 oct	06 nov	20 nov
2014	23 oct	15 oct	22 oct	12 nov	19 nov
2015	08 oct	07 oct	15 oct	21 oct	28 oct
2016	—	05 oct	—	—	19 oct
2017	—	08 nov	—	12 oct	18 oct
2018	—	07 nov	24 oct	—	18 oct
2019	—	—	—	09 oct	—

Nota

Las 24 combinaciones año-grado con datos generan exactamente 24 fechas de examen distintas.
El Script 06 pre-filtra crímenes al período [fecha - 365 días, fecha], antes de aplicar cada ventana específica.

05

Cruce Espacial

Script 06 · Geocódigos · Buffers · Cobertura geográfica

Script 06 · El problema del GEOCODIGO

Estructura del GEOCODIGO INE

Fuente	Dígitos	Nivel geográfico	Ejemplo	Entidades únicas
Shapefile INE	14 dígitos	Sub-manzana (entidad más pequeña)	13101001001001	46,002
Dataset de crimen	11 dígitos	Manzana censal	13101001001	1,655 con crimen
Join aplicado	11 dígitos	Truncar shapefile a 11 + disolver	13101001001	Match rate: 99.5%

Anatomía del código GEOCODIGO (11 dígitos = manzana)



Ejemplo: 1 31 01 001 001 → Región RM, Santiago, Distrito 01, Zona 001, Manzana 001

Script 06 · Buffers Espacio-Temporales — Configuración

Dimensión espacial — Radio del buffer

Desde el centroide del establecimiento (coordenada madre) hacia todas las manzanas censales circundantes. Proyección: UTM Zona 19S (EPSG:32719) para trabajar en metros.

400 metros

Radio principal del paper original. ≈ 5 min. caminando.

1 kilómetro

Radio alternativo para análisis.

Dimensión temporal — Ventana previa al examen

Días previos a la fecha exacta del examen SIMCE. Permite comparar efectos de corto, mediano y largo plazo.

7 días	Efecto inmediato
14 días	Efecto muy corto plazo
30 días	Ventana principal (paper)
90 días	Trimestre previo
180 días	Semestre previo
365 días	Año previo

Volumen de output: 24 combos año-grado × 2 radios × 6 ventanas = 595,152 filas de exposición al crimen por establecimiento

Script 06 · Fórmula del Índice de Exposición (IDW) → ponderación inversa a la distancia

$$peso_m = 1 / (1 + dist_metros_m)$$

$$indice_exp = \Sigma m \left(indice_m \times peso_m \times frec_m \right) / \Sigma m \left(peso_m \times frec_m \right)$$

donde m indexa manzanas censales dentro del radio · dist_metros = distancia entre centroide manzana y ubicación escuela

Decaimiento por distancia

Manzanas más cercanas a la escuela tienen mayor peso. Una manzana a 0m pesa 1.0; a 100m pesa 0.91; a 400m pesa 0.71.

Ponderado por frecuencia

Manzanas con más denuncias también contribuyen más al índice, dentro del mismo esquema de pesos.

Continuidad y comparabilidad

El resultado está acotado en [0,1] por construcción (hereda el rango de indice_delictualidad). Comparable entre escuelas y años.

IDW vs buffer simple

Un buffer sin pesos trata igual a una manzana en la puerta de la escuela que a una en el borde del radio. IDW es más realista.

¿Para qué sirve?

Tenemos crimenes a nivel de manzana censal, pero necesitamos saber cuánto crimen "le llega" a cada colegio. Un colegio no está en una sola manzana tiene varias manzanas alrededor, algunas muy cerca y otras más lejos. El índice de exposición convierte ese vecindario de manzanas en un número único por colegio.

Script 06–07 · Cobertura geográfica — Comunas sin datos policiales

4,133
RBDs con coordenada (total RM)

3,472
RBDs con cobertura policial completa

661
RBDs en comunas sin cobertura (16%)

18
comunas periféricas sin datos

Comunas afectadas (identificadas por cod_com_rbd numérico, NO por nombre)

Provincia	Comunas sin cobertura policial	RBDs afectados
Cordillera	Pirque (13202), San José de Maipo (13203)	38
Chacabuco	Colina (13301), Lampa (13302), Til Til (13303)	160
Maipo	Buin (13402), Calera de Tango (13403), Paine (13404)	125
Melipilla	Melipilla (13501), Alhué (13502), Curacaví (13503), María Pinto (13504), San Pedro (13505)	150
Talagante	Talagante (13601), El Monte (13602), Isla de Maipo (13603), Peñaflor (13605)	178
TOTAL	**18 comunas — todas periféricas y rurales de la RM**	**~661 RBDs**

Decisión Metodológica · Exclusión de escuelas sin cobertura

Punto a validar

661 RBDs (16% del total) están en comunas periféricas de la RM sin datos policiales. La decisión de cómo tratarlos afecta directamente la validez del estudio. Se propone excluirlos del análisis principal y documentarlos como limitación.

Opción A: Excluir del análisis (implementada)

Flag sin_cobertura_crimen=True. Se excluyen de modelos OLS. Sus ceros en indice_exp no son ceros reales. N efectivo: ~1,417 RBDs.

Opción B: Imputar indice_exp=0

incorrecto metodológicamente. Asignar cero implicaría que esas escuelas tienen exposición nula, no que los datos no existen. Sesgaría el estimador hacia cero.

Nota
El código usa cod_com_rbd numérico (≥13202) para identificar comunas sin cobertura, NO nom_com_rbd (que aparece truncado e inconsistente entre años: 'TALAGANTE' vs 'Talagante' vs 'TALAG').

06

Tabla Final

Scripts 07–08 · Tabla analítica maestra · OLS con HC3

Script 07 · tabla_final_escuelas_crimen.parquet — Estructura

195,114
filas totales
(32,519 × 6 ventanas)

57
columnas

1,417
RBDs con cobertura
(ventana 30d)

~661
RBDs flaggeados
(sin_cobertura=True)

Grupo de columnas	Columnas principales	Descripción
Llaves	rbd, agno, grado, ventana_dias	Identificador único de cada observación
Identidad	nom_rbd, cod_com_rbd, nom_com_rbd	Usar cod_com_rbd numérico (nom es inconsistente entre años)
Controles	cod_depe2, cod_grupo	Normalizados (1–3 y 1–5) — listos para regresión
Outcomes	prom_lect, prom_mate	Puntaje del grado correspondiente (extraído por Script 07)
Crimen 400m	indice_exp_400m, frec_total_400m, n_nivel_1..8_400m	Índice IDW + conteos por nivel en buffer de 400m
Crimen 1km	indice_exp_1km, frec_total_1km, n_nivel_1..8_1km	Ídem en buffer de 1 kilómetro
Flag	sin_cobertura_crimen	True = excluir de regresiones (comunas periféricas sin datos)
Tiempo	fecha_examen	Fecha exacta del examen (ancla de la ventana temporal)

Script 08 · tabla final

$$prom_score = \beta_0 + \beta_1 \cdot indice_exp + \beta_2 \cdot C(cod_grupo) + \beta_3 \cdot C(cod_depe2) + \varepsilon$$

Errores estándar robustos HC3 · 45 modelos (24 combos año-grado × 2 asignaturas, menos combos sin datos) · 2 índices de crimen

Elemento	Detalle / Valores	Referencia (baseline)
indice_exp (principal)	indice_exp_400m — Índice Global. Ventana: 30 días.	—
indice_exp (alternativo)	Σ(n_nivel_1+n_nivel_2+n_nivel_3)_400m — Índice Cluster	—
cod_grupo	1=Bajo · 2=Medio bajo · 3=Medio · 4=Medio alto · 5=Alto	Grupo Bajo (1)
cod_depe2	1=Municipal · 2=Particular Subvencionado · 3=Particular Pagado	Municipal (1)
Errores estándar	HC3 (heteroskedasticity-consistent, robusto)	—
Filtro de muestra	sin_cobertura_crimen=False · ventana_dias=30 · radio=400m	~1,417 RBDs
Outputs	regression_global/cluster_index.csv + tabla_resumen_*.csv	data/resultados/

Script 08 · Los Dos Índices de Crimen — Global vs. Cluster

	Índice Global (v2)	Índice Cluster (v3)
Tipo de variable	Continuo [0, 1]	Entero (conteo bruto)
Fórmula	IDW: Σ(indice_m × peso_m × frec_m) / Σ(peso_m × frec_m)	Σ(n_nivel_1 + n_nivel_2 + n_nivel_3) en buffer
Delitos incluidos	Los 98 tipos — ponderados por score_gravedad	Solo niveles 1–3: violencia letal, violencia grave, armas/robos
Qué captura	Exposición general al crimen, ponderada por severidad y distancia	Exposición específica a crimen grave y violento
Sensibilidad	Alta variación continua — capta efectos moderados	Baja frecuencia — solo captura eventos muy graves
Construcción en paper	Promedio ponderado (idéntico al nuestro)	k-means K=6 sobre el ranking de severidad
Construcción nuestra	Idéntico al paper	Aproximación: niveles 1–3 directamente (sin k-means)
Resultados	**28/45 sig. (62%) · 91% negativos**	**2/45 sig. (4%) — consistente con paper**

El paper usa k-means K=6 para definir el cluster. Nosotros usamos niveles de severidad 1–3 directamente. El resultado debería ser similar pero no idéntico. ¿Es aceptable esta aproximación para la validación final?

07

Resultados y Sanity Check

Índice Global · Índice Cluster · Comparativo vs. paper

Resultados · Índice Global (v2) — Síntesis por Año

45
modelos corridos
(año × grado × asignatura)

28/45
modelos significativos
(62%)

91%
coeficientes negativos
(dirección esperada)

−10.0
coef. más fuerte
(4b Mate 2014, p<0.001)

Año	Modelos corridos	Significativos	% Negativos	Coef. representativo	R^2 Adj. rango
2013	9	6	89%	4b Mate: β=−5.5 (*)	0.42–0.56
2014	8	7	100%	4b Mate: β=−10.0 (***)	0.44–0.55
2015	8	7	88%	8b Mate: β=−7.9 (**)	0.47–0.56
2016	4	0	50%	2m Lect: β=+1.1 (ns)	0.24–0.49
2017	6	3	83%	4b Lect: β=−6.1 (*)	0.33–0.56
2018	6	3	100%	2m Lect: β=−6.8 (*)	0.31–0.53
2019	2	0	50%	8b Mate: β=−4.4 (+)	0.43–0.51
TOTAL	**45**	**28 (62%)**	**91%**	Patrón negativo consistente 2013–2018	0.25–0.56

Resultados · Índice Cluster (v3) — Síntesis

45	2/45	58%	~0.01
modelos corridos	significativos (4%)	coeficientes negativos (ruidoso)	coef. típico (escala: conteo de eventos)

¿Por qué tan pocos modelos significativos?

- El índice Cluster es un conteo bruto de eventos graves (homicidios, robos con violencia, etc.) — estos son eventos POCO FRECUENTES. La varianza es baja.
- Con poca varianza, el poder estadístico para detectar un efecto es menor. No es evidencia de ausencia de efecto, sino de limitación del estimador.
- El paper original reporta el mismo patrón: solo 2/45 modelos significativos para el Cluster v3.
- Los coeficientes son mayoritariamente negativos (58%) — consistente con la dirección esperada, aunque el ruido es alto.

Comparación directa con el paper

Paper original: 2/45 sig. para Cluster v3. Nuestro resultado: 2/45 sig. para Cluster aproximado (niveles 1–3). La replicación es exacta en número de modelos significativos. La diferencia en coeficientes puntuales se explica por la diferencia metodológica en construcción del índice (k-means vs. niveles 1–3).

Sanity Check · Comparativo: Paper Original vs. Pipeline v3

Aspecto	Paper original (referencia)	Pipeline v3 (nuestro)	Estado
Período analizado	2013–2019	2013–2019	✓ Igual
Índice Global (v2)	Promedio ponderado frec × severidad	Idéntico — replicado exactamente	✓ Replicado
Índice Cluster (v3)	k-means K=6 sobre ranking severidad	Aproximación: Σ niveles 1–3	Aprox.
Radio buffer principal	400 metros	400 metros + 1km adicional	✓ Ampliado
Ventana temporal principal	30 días	30 días (+ 5 ventanas adicionales: 7–365 días)	✓ Ampliado
N escuelas (~4b 2013)	~1,600	~1,362 (−238 por exclusión sin cobertura)	Documentado
Errores estándar	HC3	HC3	✓ Igual
Controles	cod_grupo + cod_depe2	Idénticos — normalizados explícitamente	✓ Igual
Sig. Global (total 45 modelos)	28/45 (62%)	28/45 (62%)	✓ Match exacto
Sig. Cluster (total 45 modelos)	2/45 (4%)	2/45 (4%)	✓ Match exacto
Dirección coeficientes Global	~91% negativos	91% negativos	✓ Match exacto
Código disponible	No	Sí — 8 scripts Python, documentado	✓ Mejorado

08

Lins relevantes

Links

- Fuente datos establecimientos: https://datosabiertos.mineduc.cl/
- Fuente shapefiles RM: https://www.ine.gob.cl/herramientas/portal-de-mapas/geodatos-abiertos