# Documentación Técnica del Pipeline de datos

## Crimen y Educación, Región Metropolitana 2013–2019

*Realizado por Camila Vera Villa | Marzo 2026*

Este documento describe en detalle cada componente del pipeline de datos construido para replicar y extender el análisis del paper «Impact of Crime Exposure on Educational Performance in Santiago de Chile (2013–2019)».

Incluye:

(1) Flujo de trabajo completo.

(2) Documentación de cada script.

(3) Diccionarios de datos de cada tabla intermedia y final.

Datos generales:

**Versión del pipeline:** v3 (Índice Global v2 + Índice Cluster v3)
**Período cubierto:** 2013 - 2019 (datos SIMCE) | 2013 - 2022 (datos crimen)
**Cobertura geográfica:** Región Metropolitana - 35 comunas con cobertura criminal
**Universo de análisis:** 1,417 establecimientos (RBD) con cobertura de datos criminales
**Scripts:** 8 scripts modulares (01–08) + project_paths.py
**Lenguaje:** Python 3.10+ | Dependencias: pandas, geopandas, statsmodels

## PARTE 1: Flujo de trabajo

El pipeline se organiza en 8 scripts secuenciales. Cada script tiene un propósito único, recibe inputs bien definidos y produce outputs que alimentan al siguiente. El diseño modular permite correr cualquier script por separado si los inputs ya existen.

| Paso | Script | Función principal | Output principal |
|---|---|---|---|
| 1 | 01_create_crime_severity_lookup.py | Define ranking de severidad de 98 tipos de delito | crime_severity_lookup.csv |
| 2 | 02_validate_and_score_lookup.py | Valida y recomputa scores sin tocar datos crudos | crime_severity_lookup.csv (actualizado) |
| 3 | 03_create_crime_index_by_geocode.py | Agrega delitos por geocódigo-fecha y calcula índice diario | crime_index_geocode_daily.csv |
| 4 | 04_dataprep_schools.py | Limpia y geocodifica establecimientos educacionales | school_locations_RM.parquet |
| 5 | 05_dataprep_education.py | Prepara tabla SIMCE con controles y coordenadas | data_education_2013_2019_RM.parquet |
| 6 | 06_spatial_buffers.py | Calcula exposición al crimen por escuela (buffer espacio-temporal) | crime_exposure_400m/1km.parquet |
| 7 | 07_final_table.py | Une educación + crimen + flags geográficos | tabla_final_escuelas_crimen.parquet |
| 8 | 08_regression_analysis.py | Corre modelos OLS y genera tablas de resultados | regression_global/cluster_index.csv |

**Orden de ejecución obligatorio (dependencias en cadena):**

```
python scripts/01_create_crime_severity_lookup.py
python scripts/02_validate_and_score_lookup.py
python scripts/03_create_crime_index_by_geocode.py
python scripts/04_dataprep_schools.py
python scripts/05_dataprep_education.py     # depende de 04
python scripts/06_spatial_buffers.py        # depende de 03, 04, 05
python scripts/07_final_table.py            # depende de 05, 06
python scripts/08_regression_analysis.py    # depende de 07
```

**Estructura de carpetas del proyecto:**

```
crime_education_project/
  config/
    crime_severity_lookup.csv       ← ranking de 98 tipos de delito
  data/
    raw/
      listado_delitos.csv           ← 3,678,197 denuncias policiales
      Directorios_mineduc/          ← directorios MINEDUC por año
      shapefiles/
        rm_manzanas_geocodigo.shp   ← polígonos de manzanas INE (RM)
    intermediate/
      crime_index_geocode_daily.csv ← índice por geocódigo × fecha
      crime_detail_geocode_daily.csv
      crime_index_georef.parquet    ← con coordenadas lat/lon
      crime_exposure_400m.parquet   ← exposición por escuela (buffer 400m)
      crime_exposure_1km.parquet
    processed/
      school_locations_RM.parquet   ← 4,133 RBDs con coordenadas
      data_education_2013_2019_RM.parquet  ← SIMCE listo para análisis
      tabla_final_escuelas_crimen.parquet  ← tabla maestra
      tabla_final_30d.csv           ← subconjunto ventana 30 días
    resultados/
      regression_global_index.csv
      regression_cluster_index.csv
      tabla_resumen_global.csv
      tabla_resumen_cluster.csv
  scripts/
    project_paths.py                ← centraliza todas las rutas
    01_create_crime_severity_lookup.py
    ... (08 scripts en total)
```

# PARTE 2: Documentación de Scripts

## project_paths.py - Rutas centralizadas

Archivo de configuración central que define todas las rutas del proyecto usando pathlib.Path. Todos los demás scripts importan sus rutas desde aquí. Editar este archivo si se cambia la estructura de carpetas.

**Ubicación**: scripts/project_paths.py

**Función**: ningún input de datos. Define constantes como RAW_CRIME_DATA_PATH, CRIME_SEVERITY_LOOKUP_PATH, EDUCATION_OUTPUT_PATH, FINAL_TABLE_PATH, etc.

→ **Si se mueve el proyecto a otro servidor, basta con modificar project_paths.py. No es necesario tocar ningún otro script.**

## Script 01 - create_crime_severity_lookup.py

**Ubicación**: scripts/01_create_crime_severity_lookup.py

**Propósito**: Construir la tabla de referencia de severidad criminal (lookup). Este script contiene el corazón de la lógica de clasificación del ranking manual de 98 tipos de delito.

| INPUTS | OUTPUTS |
|---|---|
| `data/raw/listado_delitos.csv` | `config/crime_severity_lookup.csv` |

### ¿Qué hace?

- Lee listado_delitos.csv para extraer los 98 tipos de delito únicos del dataset.
- Valida que el ranking interno (RANKING_PROPUESTO) sea completo (1..98 sin saltos ni duplicados).
- Valida que todos los tipos de delito del CSV tengan ranking asignado.
- Calcula score_gravedad = (98 - rank) / 97 → normalizado [0,1] donde 1=más grave.
- Asigna nivel_gravedad (1–8) y grupo_gravedad según NIVEL_CONFIG.
- Guarda el resultado en config/crime_severity_lookup.csv.

Nota: Este ranking es editable manualmente en el script y puede modificarse sin afectar los datos raw.

### Ranking de severidad → 8 niveles

| Nivel | Nombre | Rango ranks | Score aprox. | Ejemplo |
|---|---|---|---|---|
| 1 | violencia_letal_extrema | 1–5 | 1.00 – 0.96 | Homicidio, Secuestro, Violación |
| 2 | violencia_grave | 6–12 | 0.95 – 0.89 | Robo con violencia, Lesiones graves, VIF |
| 3 | armas_y_robos | 13–26 | 0.88 – 0.75 | Porte ilegal armas, Robo vehículo |
| 4 | propiedad_lesiones_sexuales | 27–46 | 0.74 – 0.54 | Hurto, Lesiones leves, Abuso sexual |
| 5 | drogas | 47–52 | 0.53 – 0.48 | Tráfico, Microtráfico, Consumo de droga |
| 6 | economicos_institucionales | 53–65 | 0.47 – 0.34 | Falsificación, Cohecho, Daños |
| 7 | orden_publico_infracciones | 66–81 | 0.33 – 0.18 | Ley de tránsito, Ley de alcoholes |
| 8 | incivilidades | 82–98 | 0.17 – 0.00 | Ruidos molestos, Ebriedad, Ley tabaco |

## Script 02 - validate_and_score_lookup.py

**Ubicación**: scripts/02_validate_and_score_lookup.py

**Propósito**: Recomputar y revalidar crime_severity_lookup.csv si se modifica el ranking en el Script 01, sin necesidad de correr el Script 01 completo.

| INPUTS | OUTPUTS |
|---|---|
| `config/crime_severity_lookup.csv (existente)` | `config/crime_severity_lookup.csv (revalidado)` |

→ Este script es útil para ajustes iterativos del ranking. Permite experimentar con distintas clasificaciones de severidad sin reejecutar todo el pipeline desde cero.

## Script 03 - create_crime_index_by_geocode.py

**Ubicación**: scripts/03_create_crime_index_by_geocode.py

**Propósito**: Agregar los 3.6 millones de registros de delitos al nivel geocódigo × fecha y calcular el Índice de Delictualidad diario.

| INPUTS | OUTPUTS |
|---|---|
| `data/raw/listado_delitos.csv` | `data/intermediate/crime_index_geocode_daily.csv` |
| `config/crime_severity_lookup.csv` | `data/intermediate/crime_index_geocode_monthly.csv` |
| | `data/intermediate/crime_detail_geocode_daily.csv` |
| | `data/intermediate/crime_detail_geocode_monthly.csv` |

### Fórmula del Índice de Delictualidad

Para cada par (GEOCODIGO, fecha):

```
weighted_score_i    = frecuencia_i × score_gravedad_i
indice_delictualidad = Σ(weighted_score_i) / Σ(frecuencia_i)
```

Donde la sumatoria corre sobre todos los tipos de delito i registrados en ese geocódigo ese día. El resultado es un promedio ponderado de severidad, donde los delitos más frecuentes tienen mayor peso. Retorna 0 si no hay delitos.

### Estructura del GEOCODIGO

El shapefile INE contiene GEOCODIGOs de 14 dígitos (nivel sub-manzana). Los datos de crimen usan GEOCODIGOs de 11 dígitos (nivel manzana). Para el join espacial se truncan los 14 dígitos a 11, y luego se disuelven las sub-manzanas en manzanas, obteniendo 1,655 manzanas únicas con geometría.

> **Cobertura: el 99.5% de los GEOCODIGOs del dataset de crimen tienen geometría en el shapefile. El 0.5% restante no puede ser geolocalizado y se excluye del análisis espacial.**

## Script 04 - dataprep_schools.py

**Ubicación**: scripts/04_dataprep_schools.py

**Propósito**: Construir un directorio limpio de establecimientos educacionales de la RM con coordenadas geográficas únicas (una coordenada por RBD).

| INPUTS | OUTPUTS |
|---|---|
| data/raw/Directorios_mineduc/Directorio_oficial_EE_*.csv (2013-2019) | data/processed/school_locations_RM.parquet |
| | data/processed/schools_clean_2013_2019_RM.parquet |

### Cálculo de la Coordenada Madre

Un mismo RBD puede reportar coordenadas ligeramente distintas en diferentes años (errores de captura, redondeo). Para obtener una coordenada única y estable por establecimiento, se calcula la 'coordenada madre':

```
latitud_madre  = moda(lat redondeada a 4 decimales)
longitud_madre = moda(lon redondeada a 4 decimales)
```

El redondeo a 4 decimales corresponde a ~11 metros de precisión, suficiente para el análisis de buffers de 400m y 1km. La moda es robusta a outliers por error de captura.

> **Nota: Se usa la moda (no la media) para evitar que un dato erróneo desplace la coordenada hacia un punto intermedio incorrecto. Por ejemplo, si un establecimiento tiene coordenadas correctas en 6 años y una incorrecta en 1, la moda selecciona la correcta.**

## Script 05 - dataprep_education.py

**Ubicación**: scripts/05_dataprep_education.py

**Propósito**: Preparar la tabla de datos educativos (SIMCE 2013–2019 RM) con variables de control normalizadas, fechas de examen y coordenadas de cada establecimiento.

| INPUTS | OUTPUTS |
|---|---|
| data/processed/simce_completo_5.dta ← Stata .dta | data/processed/data_education_2013_2019_RM.parquet |
| data/processed/schools_clean_2013_2019_RM.parquet | |

### Normalización de variables categóricas Stata

El archivo .dta usa variables categóricas con etiquetas. Al leer con pandas (convert_categoricals=False), estas aparecen como enteros con distintos esquemas de codificación según año:

| Variable | Años 2013–2017 | Años 2018–2019 | Interpretación |
|---|---|---|---|
| cod_depe2 | 1=Municipal, 2=Part.Sub, 3=Part.Pag | 4=Municipal, 5=Part.Sub, 6=Part.Pag | Dependencia administrativa del establecimiento |
| cod_grupo | 1=Bajo … 5=Alto | 6=Bajo … 10=Alto | Grupo socioeconómico SIMCE |

El script normaliza ambas variables a escala 1–3 y 1–5 respectivamente, independientemente del año.

### Consideraciones importantes

- **El archivo .dta debe leerse con convert_categoricals=False. Si se lee con conversión de categoricals (comportamiento por defecto), los valores string de las etiquetas no se mapean correctamente al hacer .copy() sobre subconjuntos.**
- La columna **fecha_rendicion** contiene la fecha exacta del examen SIMCE para cada combinación agno-grado. Hay exactamente 1 fecha distinta por combinación (confirmado empíricamente). Esta fecha es usada por el Script 06 para calcular las ventanas temporales.

## Script 06 - spatial_buffers.py

**Ubicación**: scripts/06_spatial_buffers.py

**Propósito**: Calcular el índice de exposición al crimen para cada escuela, para múltiples ventanas temporales (7, 14, 30, 90, 180 y 365 días antes del SIMCE) y dos radios espaciales (400m y 1km).

| INPUTS | OUTPUTS |
|---|---|
| data/intermediate/crime_index_geocode_daily.csv | data/intermediate/crime_exposure_400m.parquet |
| data/intermediate/crime_detail_geocode_daily.csv | data/intermediate/crime_exposure_1km.parquet |
| data/processed/school_locations_RM.parquet | data/intermediate/crime_index_georef.parquet |
| data/processed/data_education_2013_2019_RM.parquet | data/intermediate/crime_detail_georef.parquet |
| data/raw/shapefiles/rm_manzanas_geocodigo.shp | |

### Arquitectura del cálculo espacial

- Las coordenadas de las escuelas (WGS84 / EPSG:4326) se reproyectan a UTM Zona 19S (EPSG:32719) para trabajar en metros.
- Para cada combinación (agno, grado), se obtiene la fecha exacta del examen desde fecha_rendicion.
- Se pre-filtran los crímenes al período [fecha_examen - 365 días, fecha_examen] para reducir cómputo.
- Para cada ventana temporal N (7, 14, 30, 90, 180, 365 días), se filtra al subconjunto [fecha - N, fecha].
- Para cada radio R (400m, 1km), se identifican todas las manzanas censales dentro del radio desde el centroide de la escuela.
- Se calcula la distancia en metros entre el centroide de cada manzana y la ubicación de la escuela.

### Fórmula del Índice de Exposición (indice_exp)

El índice incorpora un factor de decaimiento por distancia inversa (IDW — Inverse Distance Weighting):

```
peso_m     = 1 / (1 + dist_metros_m)
indice_exp = Σ_m(indice_m × peso_m × frec_m) / Σ_m(peso_m × frec_m)
```

Donde *m* indexa manzanas dentro del buffer. Las manzanas más cercanas a la escuela pesan más. *frec_m* es la frecuencia total de delitos en la manzana m en la ventana temporal.

### Decisión crítica: Exclusión de establecimientos sin cobertura

> **IMPORTANTE: 334 RBDs (19.1% del total) corresponden a comunas periféricas de la RM que NO tienen datos de crimen en el dataset policial. Estas son: Pirque, San José de Maipo, Colina, Lampa, Til Til, Buin, Calera de Tango, Paine, Melipilla, Alhué, Curacaví, María Pinto, San Pedro, Talagante, El Monte, Isla de Maipo, Padre Hurtado y Peñaflor. Se les asigna flag *sin_cobertura_crimen=True*. No se les asigna indice_exp=0 (sería incorrecto: sus ceros reflejarían ausencia de datos, no ausencia real de crimen). Se EXCLUYEN de los modelos de regresión.**

Identificación de RBDs sin cobertura: se usa cod_com_rbd numérico (NOT nom_com_rbd) porque los nombres de comunas aparecen truncados e inconsistentes entre años (ej. 'TALAGANTE' vs 'Talagante' vs 'TALAG'). Los códigos numéricos son estables.

**Fechas exactas de examen SIMCE utilizadas**

| Año | 2° Básico | 4° Básico | 6° Básico | 8° Básico | 2° Medio |
|---|---|---|---|---|---|
| 2013 | 29 Oct | 09 Oct | 23 Oct | 06 Nov | 20 Nov |
| 2014 | 23 Oct | 15 Oct | 22 Oct | 12 Nov | 19 Nov |
| 2015 | 08 Oct | 07 Oct | 15 Oct | 21 Oct | 28 Oct |
| 2016 | — | 05 Oct | — | — | 19 Oct |
| 2017 | — | 08 Nov | — | 12 Oct | 18 Oct |
| 2018 | — | 07 Nov | 24 Oct | — | 18 Oct |
| 2019 | — | — | — | 09 Oct | — |

→ Las fechas exactas provienen de la columna fecha_rendicion del SIMCE (no son aproximaciones). Hay exactamente 1 fecha distinta por combinación agno-grado confirmado sobre los 32,519 registros.

## Script 07 - final_table.py

**Ubicación**: scripts/07_final_table.py

**Propósito**: Unir los datos educativos con los índices de exposición criminal para producir la tabla maestra. Resultado: 195,114 filas (32,519 combos RBD×año×grado × 6 ventanas temporales).

| INPUTS | OUTPUTS |
|---|---|
| data/processed/data_education_2013_2019_RM.parquet | data/processed/tabla_final_escuelas_crimen.parquet |
| data/intermediate/crime_exposure_400m.parquet | data/processed/tabla_final_30d.csv ← subconjunto ventana=30d |
| data/intermediate/crime_exposure_1km.parquet | |

**Extracción del puntaje por grado (curso)**

La tabla SIMCE tiene columnas de puntaje para todos los grados (prom_lect2b_rbd, prom_lect4b_rbd, etc.) en cada fila. El Script 07 extrae el puntaje correspondiente al grado de cada fila y lo coloca en las columnas genéricas prom_lect y prom_mate. Esto permite que el Script 08 use una fórmula de regresión uniforme independientemente del grado.

**El flag *sin_cobertura_crimen* se propaga a nivel de RBD: si un RBD no tiene cobertura criminal en algún año, se marca en TODOS sus registros para todos los años y grados.**

## Script 08 - regression_analysis.py

**Ubicación**: scripts/08_regression_analysis.py

**Propósito**: Replicar los modelos OLS del paper. Corre 45 modelos × 2 índices = 90 regresiones en total.

| INPUTS | OUTPUTS |
|---|---|
| data/processed/tabla_final_escuelas_crimen.parquet | data/resultados/regression_global_index.csv |
| | data/resultados/regression_cluster_index.csv |
| | data/resultados/tabla_resumen_global.csv |
| | data/resultados/tabla_resumen_cluster.csv |

### Especificación econométrica

$$\text{prom_lect (o prom_mate)} = \beta_0 + \beta_1 \cdot \text{indice_exp} + C(\text{cod_grupo}) + C(\text{cod_depe2}) + \varepsilon$$

| Elemento | Detalle |
|---|---|
| **Variable dependiente** | Puntaje promedio SIMCE de lectura o matemáticas del establecimiento |
| **Variable principal** | indice_exp_400m (Índice Global) o sum(n_nivel_1+n_nivel_2+n_nivel_3)_400m (Cluster) |
| **Ventana temporal** | 30 días (VENTANA_PRINCIPAL — configurable) |
| **Radio espacial** | 400 metros (RADIO_PRINCIPAL — configurable) |
| **Control 1: cod_grupo** | Grupo SE: 1=Bajo (ref.), 2=Medio bajo, 3=Medio, 4=Medio alto, 5=Alto |
| **Control 2: cod_depe2** | Dependencia: 1=Municipal (ref.), 2=Part. Subvencionado, 3=Part. Pagado |
| **Errores estándar** | HC3 (heteroskedasticity-consistent) — robustos a varianza no constante |
| **Filtro** | sin_cobertura_crimen=False — excluye 334 RBDs sin datos criminales |
| **Muestra efectiva** | ~1,417 RBDs \| ~27,614 obs. (ventana 30d, radio 400m) |

### Índice Cluster (v3) — construcción

El Índice Cluster del paper se construye como el conteo de delitos de los niveles de severidad más altos (1, 2 y 3). En el Script 08 se calcula sumando las columnas:

```
indice_cluster = n_nivel_1_400m + n_nivel_2_400m + n_nivel_3_400m
```

Esto corresponde a: violencia letal extrema + violencia grave + armas y robos. No es un promedio ponderado sino un conteo bruto de eventos graves.

## PARTE 3: Diccionarios de datos

Se detalla cada columna de las tablas creadas en el pipeline, con su tipo de dato y descripción.

### config/crime_severity_lookup.csv

Tabla de referencia de severidad. 98 filas, una por tipo de delito. Generada por Scripts 01/02.

| Columna | Tipo | Descripción |
|---|---|---|
| delito | str | Nombre exacto del tipo de delito (debe coincidir con columna 'delito' del CSV de crimen) |
| rank_gravedad | int | Ranking manual: 1 = más grave (Homicidio), 98 = menos grave (Desacato a autoridad) |
| score_gravedad | float [0,1] | Score normalizado: (98 - rank) / 97. Homicidio=1.0, Desacato=0.0 |
| nivel_gravedad | int [1-8] | Nivel de severidad: 1=letal extrema, 2=grave, 3=armas/robos, ..., 8=incivilidades |
| grupo_gravedad | str | Nombre descriptivo del nivel (ej: 'violencia_letal_extrema', 'drogas') |
| comentario | str / NA | Campo libre para anotaciones (no se usa en cómputos) |

### data/intermediate/crime_index_geocode_daily.csv

Índice de criminalidad diario por geocódigo (manzana censal). Una fila por GEOCODIGO × día. ~2.3M filas. Generado por Script 03.

| Columna | Tipo | Descripción |
|---|---|---|
| GEOCODIGO | str (11 dígitos) | Código de manzana censal INE (11 dígitos, ej: '13101001001') |
| dia | str (fecha) | Fecha completa 'YYYY-MM-DD' del registro |
| anio | int | Año del registro (extraído de dia) |
| indice_delictualidad | float [0,1] | Promedio ponderado de severidad: Σ(frec×score) / Σ(frec). 0 si no hay delitos. |
| frecuencia_total | int | Total de denuncias registradas en ese geocódigo ese día |
| n_delitos_distintos | int | Cantidad de tipos de delito distintos ese día |
| n_nivel_1 | int | Frecuencia de delitos nivel 1 (violencia letal extrema) |
| n_nivel_2 | int | Frecuencia de delitos nivel 2 (violencia grave) |
| n_nivel_3 | int | Frecuencia de delitos nivel 3 (armas y robos) |
| n_nivel_4 | int | Frecuencia de delitos nivel 4 (propiedad, lesiones, sexuales) |
| n_nivel_5 | int | Frecuencia de delitos nivel 5 (drogas) |
| n_nivel_6 | int | Frecuencia de delitos nivel 6 (económicos e institucionales) |
| n_nivel_7 | int | Frecuencia de delitos nivel 7 (orden público e infracciones) |
| n_nivel_8 | int | Frecuencia de delitos nivel 8 (incivilidades) |

### data/processed/school_locations_RM.parquet

Directorio de establecimientos con coordenada única. 4,133 RBDs. Generado por Script 04.

| Columna | Tipo | Descripción |
|---|---|---|
| rbd | int | Código de establecimiento MINEDUC (único por establecimiento) |
| nom_rbd | str | Nombre oficial del establecimiento |

| | | |
|---|---|---|
| cod_com_rbd | int | Código numérico de comuna (ej: 13101 = Santiago) |
| nom_com_rbd | str | Nombre de la comuna |
| latitud | float | Latitud de la coordenada madre (moda de lat redondeada a 4 dec.) |
| longitud | float | Longitud de la coordenada madre (moda de lon redondeada a 4 dec.) |
| agno | int | Año de referencia del directorio MINEDUC utilizado |

## data/processed/data_education_2013_2019_RM.parquet

Tabla de datos educativos lista para análisis. 32,519 filas (una por RBD × año × grado evaluado). Generada por Script 05.

| Columna | Tipo | Descripción |
|---|---|---|
| rbd | Int64 | Código del establecimiento MINEDUC |
| agno | Int64 | Año del examen SIMCE |
| grado | str | Grado evaluado: '2b', '4b', '6b', '8b', '2m' |
| cod_depe2 | float | Dependencia: 1=Municipal, 2=Part. Subvencionado, 3=Part. Pagado |
| cod_grupo | float | Grupo SE: 1=Bajo, 2=Medio bajo, 3=Medio, 4=Medio alto, 5=Alto |
| fecha_rendicion | date | Fecha exacta del examen SIMCE para ese agno-grado |
| id_rbd_grado | str | Llave compuesta: '{rbd}_{grado}' para joins |
| prom_lect2b_rbd | float | Puntaje promedio SIMCE Lenguaje — 2° Básico del establecimiento |
| prom_mate4b_rbd | float | Puntaje promedio SIMCE Matemáticas — 4° Básico |
| prom_lect6b_rbd | float | Puntaje promedio SIMCE Lenguaje — 6° Básico |
| prom_mate8b_rbd | float | Puntaje promedio SIMCE Matemáticas — 8° Básico |
| prom_lect2m_rbd | float | Puntaje promedio SIMCE Lenguaje — 2° Medio |
| nalu_* | float | Número de alumnos evaluados (por grado y asignatura) |
| latitud / longitud | float | Coordenada madre del establecimiento (desde Script 04) |
| cod_com_rbd | float | Código numérico de comuna (estable entre años, a diferencia del nombre) |
| nom_com_rbd | str | Nombre de la comuna (¡inconsistente entre años: mayúsculas, truncado!) |

**NOTA: nom_com_rbd es inconsistente entre años (truncado a 5 chars, mayúsculas/minúsculas variables). Para identificar comunas, siempre usar cod_com_rbd numérico.**

## data/intermediate/crime_exposure_400m.parquet / crime_exposure_1km.parquet

Índice de exposición criminal por escuela. 595,152 filas (32,519 combos × 6 ventanas × 2 archivos). Generadas por Script 06.

| Columna | Tipo | Descripción |
|---|---|---|
| rbd | int | Código del establecimiento |
| agno | int | Año del examen |
| grado | str | Grado evaluado |
| ventana_dias | int | Días previos al examen cubiertos: 7, 14, 30, 90, 180 ó 365 |
| fecha_examen | date | Fecha exacta del examen SIMCE |

| | | |
|---|---|---|
| indice_exp | float [0,1] | Índice de exposición ponderado por distancia inversa (IDW). 0 si no hay crimen en el buffer. |
| frecuencia_total | int | Total de denuncias dentro del buffer espacio-temporal |
| n_manzanas | int | Número de manzanas censales dentro del radio con al menos 1 delito |
| n_nivel_1 | int | Conteo de delitos nivel 1 en el buffer (violencia letal extrema) |
| n_nivel_2 | int | Conteo de delitos nivel 2 en el buffer (violencia grave) |
| n_nivel_3 | int | Conteo de delitos nivel 3 en el buffer (armas y robos) |
| n_nivel_4..8 | int | Conteo de delitos niveles 4 a 8 en el buffer |

**NOTA: RBDs sin cobertura geográfica tendrán indice_exp=0 en estos archivos, pero el Script 07 les asigna flag sin_cobertura_crimen=True para indicar que el cero es por ausencia de datos, no ausencia real de crimen.**

## data/processed/tabla_final_escuelas_crimen.parquet

Tabla maestra. 195,114 filas. Incluye TODOS los establecimientos (con y sin cobertura). Generada por Script 07.
Columnas principales:

| Grupo | Columnas | Descripción |
|---|---|---|
| Llaves | rbd, agno, grado, ventana_dias | Identificador único de cada observación |
| Identidad | nom_rbd, cod_com_rbd, nom_com_rbd | Nombre y ubicación administrativa |
| Controles | cod_depe2, cod_grupo | Variables de control para regresión (normalizadas 1-3 y 1-5) |
| Outcomes | prom_lect, prom_mate | Puntaje SIMCE del grado correspondiente (extraído por Script 07) |
| Ubicación | latitud, longitud | Coordenada madre del establecimiento |
| Crimen 400m | indice_exp_400m, frecuencia_total_400m, n_nivel_1_400m…n_nivel_8_400m | Indicadores de crimen en buffer de 400 metros |
| Crimen 1km | indice_exp_1km, frecuencia_total_1km, n_nivel_1_1km…n_nivel_8_1km | Indicadores de crimen en buffer de 1 kilómetro |
| Flag | sin_cobertura_crimen | True para 334 RBDs de comunas sin datos policiales. Excluir de regresiones. |
| Tiempo | fecha_examen | Fecha del examen SIMCE (desde fecha_rendicion) |

## data/resultados/regression_global_index.csv / regression_cluster_index.csv

Resultados de regresión. 45 filas (una por modelo agno × grado × asignatura). Generados por Script 08.

| Columna | Descripción |
|---|---|
| agno | Año del examen |
| grado | Grado evaluado ('2b', '4b', '6b', '8b', '2m') |
| asignatura | Outcome: 'lect' (lenguaje) o 'mate' (matemáticas) |
| n_obs | Número de observaciones usadas en el modelo (tras dropna de variables del modelo) |
| coef_crimen | Coeficiente $\beta_1$ del índice de crimen |
| se_crimen | Error estándar robusto HC3 del coeficiente |

| | |
|---|---|
| `pvalue` | P-valor del test t bilateral para $\beta_1$ |
| `significancia` | Indicador textual: '***' p<0.001, '**' p<0.01, '*' p<0.05, '+' p<0.1, '' no sig. |
| `r2` | $R^2$ del modelo |
| `r2_adj` | $R^2$ ajustado |
| `aic` | Criterio de información de Akaike |
| `bic` | Criterio de información bayesiano |
| `f_stat` | Estadístico F del modelo |
| `rmse` | Raíz del error cuadrático medio |

## Apéndice: Resumen de decisiones metodológicas

Esta tabla consolida todas las decisiones metodológicas relevantes tomadas durante la construcción del pipeline, con justificación y referencia al script donde se implementan

| Decisión | Justificación | Script |
|---|---|---|
| **Ranking manual de 98 tipos de delito en 8 niveles** | No existe un ranking oficial. Se construyó basándose en criterios penales y de impacto social. Es editable y versionable. | 01, 02 |
| **Drogas en Nivel 5 (no Nivel 3)** | Separar conceptualmente 'violencia física' de 'consumo/tráfico'. Afecta composición del Índice Cluster. | 01 |
| **Coordenada madre = moda(lat/lon redondeada a 4 dec.)** | Robustez ante errores de captura en directorios MINEDUC. 4 decimales ≈ 11m de precisión, adecuado para buffers de 400m. | 04 |
| **Radio principal: 400 metros** | Corresponde al buffer del paper original. 400m ≈ 5 min. a pie. Se evalúa también 1km. | 06 |
| **6 ventanas temporales: 7–365 días** | Permite comparar efectos de corto, mediano y largo plazo. Ventana principal del paper: 30 días. | 06 |
| **Fechas exactas de examen SIMCE desde fecha_rendicion** | Evita aproximaciones (noviembre). Se confirmó que hay exactamente 1 fecha por año-grado. | 06 |
| **Decaimiento por distancia inversa (IDW)** | Manzanas más cercanas a la escuela deberían tener mayor impacto. peso = 1/(1 + dist_metros). | 06 |
| **Truncar GEOCODIGO de 14 a 11 dígitos para el join** | Shapefile INE usa 14 dígitos (sub-manzana); datos de crimen usan 11 (manzana). Match rate: 99.5%. | 06 |
| **Excluir 334 RBDs sin cobertura policial** | Asignarles indice_exp=0 sería un error de medición (cero aparente, no real). Se marcan con flag y se excluyen de regresiones. | 07, 08 |
| **Identificar comunas sin cobertura por código numérico** | Los nombres de comunas son inconsistentes entre años (truncados, mayúsculas variables). Los códigos ≥13000 son estables. | 07 |
| **Leer .dta con convert_categoricals=False** | La conversión automática de Stata categoricals falla al hacer .copy() en pandas. Mapeo manual por enteros es más robusto. | 05 |
| **cod_depe2: mapeo distinto 2013-2017 vs 2018-2019** | El .dta usa esquemas 1-3 (años <2018) y 4-6 (años ≥2018) para los mismos 3 grupos. Mapeo explícito: {4→1, 5→2, 6→3}. | 05 |
| **cod_grupo: mapeo distinto 2013-2017 vs 2018-2019** | Igual que cod_depe2. Mapeo: {6→1, 7→2, 8→3, 9→4, 10→5}. | 05 |
| **Errores estándar HC3 (robustos)** | Corrige heteroscedasticidad en la varianza de los errores. Estándar en regresiones de datos de panel y cross-section educativos. | 08 |
| **Referencia Municipal para cod_depe2** | Municipal = establecimiento público baseline. Permite interpretar coeficientes de Part. Sub. y Part. Pagado como diferencias relativas. | 08 |